

DOCUMENT D'ANALYSE INITIALE
Projet HealthConnect -Track Data Analytics - Semaine 4
Jeu de données : HealthConnect Appointment Data

1. Aperçu du jeu de données

Le fichier HealthConnect_Appointment_Data.csv réunit 5000 rendez-vous fictifs et anonymisés, sur 18 colonnes : informations sur le patient, détails du rendez-vous, historique de fréquentation, rappels envoyés, distance à la clinique, temps d'attente, et résultat final du rendez-vous.

Ce résultat (appointment_outcome) se répartit en No-Show pour 2423 rendez-vous (48,5%), Attended pour 2314 (46,3%) et Cancelled pour 263 (5,3%). Près d'un rendez-vous sur deux se solde donc par une absence, ce qui donne la mesure du problème que la clinique cherche à résoudre.

2. Qualité des données

Pas de doublons, ni sur l'identifiant de rendez-vous ni sur des lignes entières. Les dates s'enchaînent correctement, aucun rendez-vous ne précède sa propre réservation. Trois colonnes comportent des valeurs manquantes :

Colonne	Valeurs manquantes	Observation
reminder_channel	1366 (27,3%)	Cohérent avec reminder_sent = No. À garder comme catégorie « aucun rappel », pas comme donnée manquante.
distance_to_clinic_km	90 (1,8%)	Pas d'explication évidente. À régler pendant le nettoyage.
waiting_time_minutes	60 (1,2%)	Pas d'explication évidente. À régler pendant le nettoyage.

Rien d'autre à signaler côté cohérence : le nombre de no-shows passés ne dépasse jamais le nombre de rendez-vous passés, l'âge reste dans la fourchette adulte prévue, et le temps d'attente est toujours positif.

3. Variables qui comptent

En croisant chaque variable avec le taux de no-show, certaines se détachent nettement des autres :

Variable	Écart de taux de no-show observé	Pertinence
----------	----------------------------------	------------

booking_lead_days	24,8% (0-3j) à 60,5% (30j+)	Fort , la variable qui pèse le plus dans les données
previous_no_shows	43,5% (0) à 68,8% (3j+)	Fort , l'effet s'accumule avec l'historique
distance_to_clinic_km	46,5% (0 - 10 km) à 57,8% (20 km+)	Modéré, surtout passé 20 km
reminder_sent	47,4% (oui) contre 51,4% (non)	Faible, et à l'inverse de ce qu'on attendrait
age_group, appointment_type, jour/heure, waiting_time_minutes	Écarts sous les 5 points	Faible pris individuellement

Le délai de réservation et l'historique de no-show ressortent clairement comme les deux facteurs à creuser en priorité.

4. Questions métier

1. Quel est le taux global de rendez-vous manqués à la clinique HealthConnect ?
2. Le délai entre la prise de rendez-vous et la date du rendez-vous joue-t-il sur le risque de no-show ?
3. Les patients ayant déjà manqué des rendez-vous sont-ils plus enclins à recommencer ?
4. La distance entre le domicile du patient et la clinique influence-t-elle l'assiduité ?
5. Un rappel de rendez-vous fait-il vraiment baisser le taux de no-show, et un canal fonctionne-t-il mieux qu'un autre ?

5. KPI potentiels

À ce stade, ces indicateurs sont seulement identifiés et justifiés — ils ne sont ni calculés ni mis en graphique.

KPI potentiel	Formule envisagée	Question liée
Taux global de no-show	(rendez-vous en no-show ÷ total des rendez-vous) × 100	Question 1 : sert de point de référence
Taux de no-show par délai de réservation	Taux calculé par tranche de booking_lead_days (0-3j, 4-7j, 8-14j, 15-30j, 30j+)	Question 2 : variable la plus déterminante repérée

Taux de récidence de no-show	Comparaison entre patients avec previous_no_shows ≥ 1 et ceux à 0	Question 3 : pour cibler les patients à risque
Taux de no-show par distance	Taux calculé par tranche de distance_to_clinic_km (0-5km, 5-10km, 10-20km, 20km+)	Question 4 : utile pour juger l'intérêt d'une téléconsultation
Efficacité du rappel selon le canal	Comparaison du taux de no-show selon reminder_channel et selon l'absence de rappel	Question 5 : levier facile à ajuster côté clinique

6. Approche envisagée

Outils

Power BI restera l'outil principal, dans la continuité de ce qui a été utilisé lors des Semaines 1 à 3, et parce qu'il servira ensuite à construire le tableau de bord de suivi des no-shows. Python viendra en appui pour des vérifications rapides, comme celles menées cette semaine. SQL et Tableau ne sont pas nécessaires ici : les données tiennent dans un simple fichier CSV, et Power BI couvre déjà le besoin de restitution.

Nettoyage à prévoir

- Décider quoi faire des valeurs manquantes sur distance_to_clinic_km (90) et waiting_time_minutes (60) , exclusion ou remplacement, selon leur poids réel une fois vérifié.
- Garder reminder_channel vide comme catégorie à part entière plutôt que comme anomalie à corriger.
- Regrouper booking_lead_days et distance_to_clinic_km en tranches, sur le même principe que celui utilisé cette semaine.

Priorités d'analyse

Le délai de réservation et l'historique de no-show seront étudiés en premier, puisque ce sont les deux variables qui ressortent le plus nettement. La distance et les rappels viendront ensuite, avec un regard sur leurs effets combinés plutôt que pris séparément